



UNIVERSIDAD ANDRÉS BELLO
FACULTAD DE CIENCIAS
EXACTAS

Proyecto de Título Ingeniería Física

Evaluación de un Modelo Híbrido Físico–Informado para la
Estimación de Potencia Fotovoltaica bajo Distintos Regímenes
de Fracción Difusa

Autor:

Nicolás Antonio Aravena Osorio

Profesor Guía:

Eduardo Jeraldo

Julio, 2026

Santiago, Chile

Índice

Nomenclatura	4
Resumen	5
1. Introducción	6
2. Planteamiento del problema	7
3. Pregunta de investigación, hipótesis y objetivos	8
3.1. Pregunta de investigación	8
3.2. Hipótesis de trabajo	8
3.3. Objetivo general	8
3.4. Objetivos específicos	8
4. Estado del arte y posicionamiento	9
4.1. Modelos físicos y modelos basados en datos	9
4.2. Enfoques híbridos físico-informados	9
4.3. Aprendizaje automático, aprendizaje profundo y XGBoost	11
4.4. Brecha abordada por esta tesis	11
5. Marco teórico	12
5.1. Irradiancia solar	12
5.2. Fracción difusa	13
5.3. PVWatts como referencia simulada	13
5.4. Estimación frente a pronóstico	14
5.5. Modelo NOCT	14
5.6. Residuo, bias y errores	15
5.7. Modelo híbrido residual con XGBoost	16

6. Metodología	17
6.1. Ubicación de estudio	17
6.2. Parámetros del sistema fotovoltaico	17
6.3. Metodología general	18
6.4. Preparación de datos PVWatts	19
6.5. Modelo NOCT y residuo	20
6.6. Criterios de filtrado y comparabilidad	22
6.7. Métricas de evaluación	22
6.8. Diagnóstico del residuo por fracción difusa	23
6.9. Modelo híbrido residual con XGBoost	24
7. Resultados	30
7.1. Base generada por PVWatts	30
7.2. Análisis Exploratorio de Datos (EDA)	31
7.3. Base final con modelo NOCT	31
7.4. Métricas globales del modelo NOCT	32
7.5. Error por régimen de fracción difusa	33
7.6. Error relativo por régimen	35
7.7. Residuo del modelo NOCT frente a la fracción difusa	35
7.8. Correlación entre fracción difusa y error	36
7.9. Comparación entre P_{NOCT} y P_{ref}	37
7.10. Modelo híbrido residual con XGBoost	38
7.11. Desempeño del modelo híbrido por régimen	41
7.12. Residuo corregido e importancia de variables	41
7.13. Validación temporal complementaria	44
8. Discusión	45
9. Alcances y limitaciones	47



10. Conclusiones	48
11. Trabajo futuro	49
A. Anexo: Glosario de Conceptos	52

Índice de figuras

1.	Diagrama de flujo metodológico para la implementación del modelo físico NOCT y el cálculo del residuo.	21
2.	Diagrama de flujo metodológico de la arquitectura del modelo híbrido residual con XGBoost.	27
3.	MAE del modelo NOCT por régimen de fracción difusa para la simulación asociada a Santiago.	34
4.	Distribución del error absoluto del modelo NOCT por régimen de fracción difusa; los valores extremos no se muestran en el boxplot.	34
5.	Distribución del error relativo del modelo NOCT por régimen de fracción difusa (los valores extremos no se muestran en el boxplot).	35
6.	Residuo del modelo NOCT en función de la fracción difusa.	36
7.	Comparación entre potencia estimada por NOCT y potencia de referencia PVWatts.	38
8.	Comparación del MAE entre el modelo físico NOCT y los modelos híbridos en el conjunto de prueba.	40
9.	MAE del modelo físico NOCT y de los modelos híbridos por régimen de fracción difusa.	41
10.	Residuo del modelo físico NOCT y del modelo híbrido con fracción difusa frente a la fracción difusa.	42
11.	Comparación entre potencia híbrida corregida y potencia de referencia PVWatts en el conjunto de prueba.	43
12.	Importancia de variables del modelo híbrido con fracción difusa.	44

Índice de tablas

1.	Clasificación de regímenes de fracción difusa.	13
2.	Coordenadas efectivas de la ubicación de estudio.	17
3.	Parámetros del sistema fotovoltaico utilizado.	18
4.	Criterios de filtrado utilizados en el diagnóstico y modelado.	22
5.	Interpretación de las métricas utilizadas.	23
6.	Variables de entrada de los modelos residuales.	26
7.	Separación temporal utilizada en el entrenamiento del modelo híbrido.	28
8.	Hiperparámetros principales de XGBoost.	28
9.	Rol de los hiperparámetros principales de XGBoost.	29
10.	Versiones principales de software utilizadas.	30
11.	Resumen de la base PVWatts generada.	30
12.	Estadísticas descriptivas de las variables principales en las observaciones válidas.	31
13.	Resumen de la base final utilizada para diagnóstico y modelado.	31
14.	Distribución de observaciones válidas por régimen de fracción difusa.	32
15.	Métricas globales del modelo NOCT frente a la referencia PVWatts.	32
16.	Métricas por régimen de fracción difusa para el modelo NOCT.	33
17.	Correlaciones entre fracción difusa y medidas de error.	36
18.	Desempeño de los modelos en el conjunto temporal de prueba.	39
19.	Comparación de MAE y RMSE en entrenamiento y prueba.	40
20.	MAE por régimen de fracción difusa en el conjunto temporal de prueba.	41
21.	Cinco variables con mayor importancia relativa en el modelo híbrido con fracción difusa.	44
22.	Resumen de validación temporal con cinco particiones, reportando promedio $\pm$ desviación estándar muestral.	45

Nomenclatura

P_{ref} : Potencia DC simulada de referencia.

ϵ : Residuo o error del modelo físico.

fd : Fracción difusa (DHI/GHI).

γ : Coeficiente térmico del módulo fotovoltaico.

θ_z : Ángulo cenital solar.

GHI : Irradiancia global horizontal.

DHI : Irradiancia difusa horizontal.

DNI : Irradiancia directa normal.

POA : Irradiancia sobre el plano del arreglo.

NOCT: Nominal Operating Cell Temperature.

Resumen

La estimación de potencia fotovoltaica depende de la correcta representación de la irradiancia incidente sobre el arreglo fotovoltaico y de las condiciones ambientales que afectan la temperatura de operación de las celdas. Los modelos físicos simplificados, como el modelo basado en NOCT (*Nominal Operating Cell Temperature*), permiten estimar potencia a partir de variables físicas principales, tales como la irradiancia sobre el plano del panel y la temperatura ambiente. Sin embargo, estos modelos no representan de manera explícita la composición directa y difusa de la radiación solar, lo que puede introducir diferencias respecto a modelos de referencia más completos.

En este trabajo se evalúa un modelo híbrido físico-informado para estimar potencia fotovoltaica. El modelo físico base corresponde a NOCT, mientras que la corrección del residuo del modelo físico se formula mediante aprendizaje residual con XGBoost. La variable central del análisis es la fracción difusa, definida como

$$fd = \frac{DHI}{GHI},$$

donde DHI corresponde a la irradiancia difusa horizontal y GHI a la irradiancia global horizontal. Esta variable permite clasificar las condiciones de irradiancia en tres regímenes: baja fracción difusa, régimen mixto y alta fracción difusa.

La metodología se implementó en cuatro componentes computacionales: descarga y preparación de datos horarios desde PVWatts para Santiago, cálculo del modelo físico NOCT, diagnóstico del residuo en función de la fracción difusa, y entrenamiento de modelos residuales con XGBoost con y sin incorporación explícita de esta variable. Para mantener consistencia espacial, se utilizaron las coordenadas efectivas de Santiago reportadas por PVWatts tanto en la solicitud de datos como en la reconstrucción de GHI .

Los resultados muestran que el modelo NOCT presenta buen ajuste general respecto a la referencia simulada, con $R^2 = 0,9968$ y MAE global de 11,05 W sobre las observaciones físicamente válidas. No obstante, el error varía según el régimen de fracción difusa. En el conjunto temporal de prueba, el MAE del modelo NOCT fue de 13,30 W. El modelo híbrido sin fracción difusa redujo este valor a 2,70 W, mientras que el modelo híbrido con fracción difusa lo redujo a 2,22 W. Estos resultados indican que el aprendizaje residual mejora de manera sustantiva al modelo físico base y que la fracción difusa aporta información incremental para corregir el residuo bajo la simulación analizada.

1. Introducción

La generación fotovoltaica constituye una de las tecnologías renovables de mayor crecimiento debido a su modularidad, disminución progresiva de costos y capacidad de integración en distintos contextos geográficos. A nivel nacional y comercial, el aumento de la integración fotovoltaica está fuertemente motivado por esquemas de incentivos, como la ley de generación distribuida (Net Billing) en Chile, así como el alza progresiva de las tarifas eléctricas, lo que ha impulsado a clientes residenciales e industriales a invertir en sistemas propios. En este escenario comercial, los proveedores típicamente basan sus proyecciones de retorno económico en estimaciones previas de generación. Por ende, cualquier sesgo sistemático en estas estimaciones puede llevar a incumplir las promesas de retorno financiero. En el contexto actual de cambio climático y de fenómenos de variabilidad interanual como ENSO (El Niño-Oscilación del Sur), se han reportado variaciones significativas en los patrones de nubosidad y, por consiguiente, en la fracción de irradiancia difusa, especialmente en la zona central de Chile. Esto hace que comprender el impacto de estas condiciones radiativas sobre la generación fotovoltaica sea un problema altamente relevante. La potencia producida por un sistema fotovoltaico depende principalmente de la irradiancia solar incidente, la temperatura de operación de las celdas, la orientación del arreglo, la inclinación del panel y las pérdidas propias del sistema.

Desde el punto de vista de la ingeniería física, la estimación de potencia fotovoltaica puede abordarse mediante modelos físicos, modelos basados en datos o combinaciones de ambos. Los modelos físicos permiten interpretar el problema a partir de relaciones entre irradiancia, temperatura y eficiencia del módulo. No obstante, su simplicidad puede limitar su capacidad para capturar fenómenos ópticos, térmicos y atmosféricos más complejos.

Uno de los factores relevantes en la caracterización de la irradiancia solar es la distinción entre radiación directa y difusa. Bajo condiciones despejadas, la radiación directa suele dominar la irradiancia incidente. En cambio, bajo nubosidad, aerosoles o dispersión atmosférica, la componente difusa puede aumentar considerablemente. Esta diferencia puede afectar el comportamiento de un modelo físico simplificado, especialmente si la formulación no distingue explícitamente entre ambas componentes.

En este contexto, se propone estudiar la fracción difusa,

$$fd = \frac{DHI}{GHI},$$

como variable diagn3stica del error del modelo NOCT. La finalidad no es asumir previamente que fd explica todo el error, sino evaluar si el residuo del modelo f3sico presenta variaciones sistem3ticas asociadas al r3gimen de irradiancia difusa.

El presente documento describe la construcci3n de la base de datos mediante PVWatts, la implementaci3n del modelo NOCT, el c3lculo del residuo, el diagn3stico por r3gimen de fracci3n difusa y la evaluaci3n de modelos h3bridos residuales con XGBoost. La comparaci3n entre modelos con y sin fracci3n difusa permite evaluar si esta variable aporta informaci3n adicional m3s all3 de otras variables f3sicas y temporales disponibles.

2. Planteamiento del problema

El modelo NOCT permite estimar la temperatura de celda y la potencia fotovoltaica de manera simple, utilizando como entradas principales la irradiancia sobre el plano del panel y la temperatura ambiente. Esta simplicidad es 3til para construir una primera aproximaci3n f3sica, pero tambi3n implica limitaciones.

En particular, el modelo NOCT utilizado como base no incorpora expl3citamente la composici3n directa y difusa de la irradiancia. Esto significa que dos condiciones con igual irradiancia sobre el plano del panel podr3an ser tratadas de manera equivalente, aunque una est3 dominada por radiaci3n directa y otra por radiaci3n difusa. F3sicamente, estas situaciones no son necesariamente equivalentes, ya que la distribuci3n angular de la radiaci3n puede influir en la potencia efectivamente convertida por el m3dulo.

Por esta raz3n, se plantea estudiar el residuo entre una potencia fotovoltaica simulada de referencia y la potencia estimada por NOCT:

$$\epsilon = P_{ref} - P_{NOCT}.$$

La pregunta central del trabajo es si dicho residuo presenta un comportamiento asociado a la fracci3n difusa y si esta informaci3n permite mejorar una correcci3n residual mediante aprendizaje supervisado.

3. Pregunta de investigación, hipótesis y objetivos

3.1. Pregunta de investigación

¿La fracción difusa $fd = DHI/GHI$ se relaciona con el error residual de un modelo físico NOCT, y su incorporación en un modelo supervisado mejora la estimación de potencia fotovoltaica respecto al modelo físico individual?

3.2. Hipótesis de trabajo

Se plantea que el error residual del modelo NOCT no es completamente aleatorio y que presenta variaciones asociadas al régimen de fracción difusa. En particular, se espera que fd permita caracterizar condiciones bajo las cuales el modelo físico simplificado presenta mayor error relativo o sesgo sistemático.

Esta hipótesis es falsable: si el residuo no presenta relación observable con fd , o si la incorporación de fd no mejora el modelo residual, el resultado indicaría que la fracción difusa no aporta información adicional significativa bajo las condiciones analizadas.

3.3. Objetivo general

Evaluar si la fracción difusa $fd = DHI/GHI$ es una variable relevante para diagnosticar y corregir el error de un modelo físico NOCT en la estimación de potencia fotovoltaica, utilizando una referencia simulada mediante PVWatts y un modelo híbrido residual basado en XGBoost.

3.4. Objetivos específicos

1. Construir y preparar una base horaria simulada mediante PVWatts, incorporando la clasificación del régimen radiativo a partir de la fracción difusa (fd).
2. Implementar un modelo físico NOCT para estimar la potencia fotovoltaica a partir de irradiancia y temperatura.
3. Analizar empíricamente el comportamiento del residuo del modelo NOCT ($\epsilon = P_{ref} - P_{NOCT}$) en función de los distintos regímenes de fracción difusa.

4. Entrenar modelos residuales basados en aprendizaje automático (XGBoost) para corregir sistemáticamente la potencia estimada por el modelo físico.
5. Evaluar el aporte incremental de la fracción difusa comparando el desempeño de un modelo híbrido con fd frente a uno sin fd , mediante una separación temporal de prueba.

4. Estado del arte y posicionamiento

4.1. Modelos físicos y modelos basados en datos

La estimación de irradiancia solar y potencia fotovoltaica ha sido abordada mediante modelos físicos, modelos de aprendizaje automático y enfoques híbridos. Los modelos físicos se construyen a partir de relaciones conocidas entre irradiancia, temperatura, geometría solar, orientación del módulo y eficiencia fotovoltaica. Su ventaja principal es la interpretabilidad: cada variable tiene un significado físico claro y las predicciones pueden evaluarse a partir de ecuaciones conocidas. Sin embargo, su desempeño puede verse limitado cuando se utilizan simplificaciones fuertes, parámetros genéricos o condiciones ambientales no modeladas explícitamente.

Los modelos basados en datos, en cambio, buscan aprender relaciones empíricas entre variables de entrada y potencia generada. Estos modelos pueden capturar no linealidades y patrones estadísticos que no aparecen de manera explícita en una formulación física simple. Su desventaja es que pueden perder interpretabilidad, depender fuertemente de la base de entrenamiento y aprender correlaciones que no necesariamente representan mecanismos físicos.

Ramadhan et al. comparan modelos físicos y modelos de aprendizaje automático para estimar irradiancia solar y potencia fotovoltaica, mostrando que los modelos basados en datos pueden mejorar la estimación bajo ciertas condiciones y con una selección adecuada de variables de entrada [1]. Este antecedente es relevante para el presente trabajo, ya que la metodología propuesta también contrasta un modelo físico base con un enfoque de corrección basado en datos.

4.2. Enfoques híbridos físico–informados

Recientemente, la integración de modelos físicos y algoritmos de aprendizaje automático ha surgido como un enfoque prometedor denominado modelado híbrido, residual o guiado por la física. En un esquema puramente basado en datos, el algoritmo debe aprender desde cero tanto

los principios físicos fundamentales (como la geometría solar o la respuesta térmica) como los patrones complejos no lineales. Esto requiere bases de datos inmensas y conlleva el riesgo de generar predicciones físicamente inconsistentes bajo condiciones meteorológicas no vistas en el entrenamiento.

En contraste, el modelado híbrido físico–informado delega la captura de la relación principal a un modelo analítico establecido (como un modelo térmico o eléctrico fotovoltaico) y utiliza el algoritmo de aprendizaje automático exclusivamente para modelar los errores sistemáticos o no linealidades residuales que la ecuación simplificada no es capaz de representar de manera determinista.

En esta tesis, el término físico–informado se utiliza en un sentido amplio: el modelo de aprendizaje automático no reemplaza al modelo físico ni incorpora ecuaciones diferenciales en la función de pérdida, sino que aprende una corrección residual sobre una estimación física previa. Por ello, el enfoque se aproxima especialmente a un esquema guiado por física mediante aprendizaje residual.

En este contexto, un enfoque híbrido no se entiende solamente como agregar más variables a un modelo estadístico. La idea central es usar el modelo físico para representar la estructura principal del problema y dejar que el modelo de datos aprenda aquello que la formulación simplificada no logra capturar. Esto reduce la carga del modelo supervisado, ya que no necesita aprender desde cero la relación dominante entre irradiancia y potencia. Además, permite interpretar el aprendizaje automático como una corrección del error físico, lo que facilita analizar bajo qué condiciones aparece la discrepancia.

La literatura reciente ha destacado sólidamente el valor de esta integración. Investigaciones como la de Santos et al. (2024) proporcionan revisiones exhaustivas que demuestran que los enfoques híbridos, al combinar ecuaciones físicas con aprendizaje automático, minimizan el error predictivo sin sacrificar la explicabilidad [6]. Por su parte, Mayer y Gróf (2022) han evidenciado empíricamente los beneficios de la hibridación en la estimación fotovoltaica, reteniendo pasos clave de modelado físico mientras se delegan los ajustes no lineales a modelos de datos [5]. Asimismo, el entendimiento del impacto de variables meteorológicas secundarias, como la fracción difusa [2], en el desempeño fotovoltaico es crucial; su efecto no lineal puede ser abordado eficazmente mediante algoritmos supervisados como XGBoost dentro de estos marcos híbridos para corregir las deficiencias físicas iniciales [6]. Estos antecedentes consolidan la validez de la metodología adoptada en esta tesis.

4.3. Aprendizaje automático, aprendizaje profundo y XGBoost

El aprendizaje profundo corresponde a una familia de modelos de aprendizaje automático basada en redes neuronales con múltiples capas. Estos modelos pueden ser muy potentes cuando existen grandes volúmenes de datos, variables de alta dimensionalidad o entradas no estructuradas, como imágenes, texto o series temporales extensas. Sin embargo, no todo problema de aprendizaje automático requiere aprendizaje profundo. En este trabajo se trabaja con una base tabular horaria, de tamaño moderado, con variables físicas ya estructuradas y con una pregunta específica: evaluar si fd aporta información incremental para corregir el residuo de un modelo físico.

Por esta razón, la corrección residual se implementa con XGBoost, un método de *gradient tree boosting* diseñado para construir ensambles de árboles de decisión regularizados [4]. Este enfoque resulta adecuado para esta etapa por cuatro razones. Primero, puede modelar relaciones no lineales entre variables meteorológicas, temporales y radiativas sin requerir una transformación funcional explícita. Segundo, funciona especialmente bien en datos tabulares. Tercero, incorpora regularización y control de complejidad, lo que ayuda a reducir sobreajuste cuando la base de datos es de tamaño moderado. Cuarto, entrega medidas de importancia de variables que, aunque no deben interpretarse como causalidad, permiten diagnosticar si una variable como fd es utilizada de forma relevante por el modelo.

En términos conceptuales, XGBoost no ajusta un único árbol de decisión. Construye una suma de árboles simples, donde cada nuevo árbol intenta corregir los errores que permanecen en la iteración anterior. Para una entrada $\mathbf{x}$, el predictor puede representarse como:

$$\hat{\epsilon}(\mathbf{x}) = \sum_{m=1}^M \nu f_m(\mathbf{x}),$$

donde f_m representa el árbol agregado en la iteración m , M es el número total de árboles y ν es la tasa de aprendizaje. En este trabajo, la salida del modelo no es directamente la potencia fotovoltaica, sino el residuo $\hat{\epsilon}$ que debe sumarse a la potencia NOCT.

4.4. Brecha abordada por esta tesis

A diferencia de trabajos que buscan reemplazar completamente la formulación física por un modelo de datos, este trabajo adopta un enfoque de *residual learning*. Es decir, el modelo físico NOCT se conserva como base interpretable y el modelo supervisado se utiliza para aprender

la discrepancia entre la referencia simulada y la estimación física. El aporte específico de esta tesis consiste en evaluar si la fracción difusa $fd = DHI/GHI$ entrega información relevante para explicar y corregir el residuo del modelo físico bajo distintos regímenes de irradiancia.

La brecha específica abordada es metodológica: no basta con mostrar que un modelo de aprendizaje automático obtiene menor error que un modelo físico. Es necesario evaluar si una variable físicamente interpretable, como la fracción difusa, aporta información adicional a la corrección residual. Por ello, el diseño experimental compara dos modelos híbridos equivalentes salvo por la presencia de fd , manteniendo el NOCT como baseline y usando una separación temporal para evitar una evaluación artificialmente optimista.

5. Marco teórico

5.1. Irradiancia solar

La irradiancia solar representa la potencia radiativa incidente por unidad de área. En aplicaciones fotovoltaicas se utilizan distintas componentes para describir la radiación disponible:

- **DNI** (*Direct Normal Irradiance*): irradiancia directa normal, correspondiente a la radiación proveniente directamente del disco solar sobre una superficie normal a los rayos solares.
- **DHI** (*Diffuse Horizontal Irradiance*): irradiancia difusa horizontal, asociada a la radiación dispersada por la atmósfera.
- **GHI** (*Global Horizontal Irradiance*): irradiancia global horizontal, que combina la componente directa proyectada sobre el plano horizontal y la componente difusa.
- **POA** (*Plane of Array Irradiance*): irradiancia sobre el plano del arreglo fotovoltaico.

La relación entre GHI , DNI y DHI puede expresarse como:

$$GHI = DNI \cos(\theta_z) + DHI,$$

donde θ_z es el ángulo cenital solar.

En el flujo actual de trabajo, DNI , DHI y POA son entregados directamente por PVWatts. La variable GHI se reconstruye mediante la ecuación anterior, utilizando la posición solar calculada

con `pvlíb`. En la implementación final, esta posición solar se calcula con las mismas coordenadas efectivas de Santiago utilizadas en la consulta a PVWatts.

5.2. Fracción difusa

La fracción difusa se define como:

$$fd = \frac{DHI}{GHI}.$$

Esta magnitud permite estimar el peso relativo de la irradiancia difusa respecto a la irradiancia global. Valores bajos de fd indican predominio de radiación directa, mientras que valores altos indican condiciones en que la radiación difusa domina. El uso de la fracción difusa como descriptor radiativo es habitual en modelos de irradiancia solar, especialmente para relacionar la componente difusa con la irradiancia global y el estado atmosférico [2].

En este trabajo se utilizan tres regímenes operativos. Los umbrales 0,3 y 0,7 no se interpretan como fronteras universales, sino como una partición simple y reproducible para separar condiciones dominadas por radiación directa, condiciones mixtas y condiciones dominadas por radiación difusa:

Tabla 1: Clasificación de regímenes de fracción difusa.

Régimen	Condición
Baja fracción difusa	$fd < 0,3$
Mixto	$0,3 \leq fd < 0,7$
Alta fracción difusa	$fd \geq 0,7$

5.3. PVWatts como referencia simulada

Desarrollado y mantenido por el National Renewable Energy Laboratory (NREL), PVWatts es una herramienta de referencia a nivel mundial para estimar el rendimiento de sistemas fotovoltaicos en función del clima local. PVWatts es utilizado en este trabajo como fuente de una potencia fotovoltaica simulada de referencia debido a su amplia aceptación en la industria para realizar estimaciones rápidas de desempeño. Para una ubicación y un conjunto de parámetros del sistema fotovoltaico, la API de PVWatts entrega salidas horarias tales como potencia DC, potencia AC, irradiancia sobre el plano del panel, temperatura ambiente, temperatura de celda y velocidad de

viento [3]. El modelo técnico de PVWatts ha sido documentado por Dobos, incluyendo supuestos y submodelos internos usados para estimar el desempeño fotovoltaico .

Es importante destacar que la potencia dc entregada por PVWatts no corresponde a una medición experimental de un panel real, sino a una simulación. En este trabajo se define:

$$P_{ref} = P_{DC, PVWatts}.$$

Para Santiago, PVWatts no encontró datos disponibles bajo el dataset `nsrdb`, por lo que se utilizó el dataset internacional `intl`. La fuente climática efectiva reportada por PVWatts corresponde a Santiago, Chile, con coordenadas $-33,3800$, $-70,7800$, elevación de 476 m y distancia cero respecto de las coordenadas usadas en la consulta. Por tanto, el caso de estudio queda espacialmente consistente: las variables meteorológicas, la geometría solar usada para reconstruir GHI y las salidas fotovoltaicas de PVWatts se asocian a Santiago.

5.4. Estimación frente a pronóstico

Un punto importante del alcance metodológico es distinguir entre estimación de potencia y pronóstico operacional. En este trabajo no se busca predecir la radiación solar futura a partir de modelos meteorológicos ni generar una herramienta de despacho en tiempo real. El objetivo es evaluar, sobre una base horaria simulada y completamente conocida, si el error de un modelo físico simplificado puede ser diagnosticado y corregido mediante aprendizaje residual.

Bajo esta definición, las variables de entrada del modelo híbrido provienen de la misma base horaria usada para construir la referencia simulada. Esto permite concentrar el análisis en la pregunta central de la tesis: si la fracción difusa aporta información adicional para corregir P_{NOCT} . Para transformar este enfoque en un sistema de pronóstico real, sería necesario reemplazar las entradas horarias conocidas por pronósticos de irradiancia, temperatura y viento, y luego validar el desempeño frente a mediciones reales.

5.5. Modelo NOCT

El modelo NOCT estima la temperatura de celda mediante una aproximación lineal entre irradiancia incidente y aumento térmico de la celda, formulación ampliamente utilizada en

modelación solar simplificada :

$$T_{c,NOCT} = T_a + \left(\frac{NOCT - 20}{800} \right) POA,$$

donde T_a es la temperatura ambiente y POA la irradiancia sobre el plano del arreglo fotovoltaico.

Luego, la potencia DC estimada por el modelo físico se calcula como:

$$P_{NOCT,raw} = P_{DC0} \left(\frac{POA}{G_{ref}} \right) [1 + \gamma(T_{c,NOCT} - T_{ref})],$$

donde P_{DC0} es la potencia nominal DC, $G_{ref} = 1000 \text{ W/m}^2$, $T_{ref} = 25^\circ\text{C}$, y γ es el coeficiente térmico. En la implementación se utiliza $\gamma = -0,004 \text{ 1/}^\circ\text{C}$, valor representativo de módulos fotovoltaicos de silicio cristalino. Este valor se mantiene fijo para definir un modelo físico simple e independiente de la parametrización interna de PVWatts.

Para hacer comparable el modelo NOCT con la salida DC de PVWatts, se aplica la misma pérdida global utilizada en la simulación:

$$P_{NOCT} = P_{NOCT,raw}(1 - L),$$

donde $L = 0,14$ representa pérdidas globales del 14 %.

5.6. Residuo, bias y errores

El residuo principal se define como:

$$\epsilon = P_{ref} - P_{NOCT}.$$

Si $\epsilon > 0$, el modelo NOCT subestima la potencia de referencia. Si $\epsilon < 0$, el modelo NOCT sobreestima la potencia de referencia.

Adicionalmente, se calcula el error absoluto:

$$|\epsilon| = |P_{ref} - P_{NOCT}|,$$

y el error relativo:

$$e_{rel} = \frac{|P_{ref} - P_{NOCT}|}{P_{ref}},$$

para valores de P_{ref} suficientemente mayores que cero. En la implementación, el error relativo se define solo cuando $P_{ref} > 50 \text{ W}$, con el fin de evitar divisiones por potencias muy pequeñas.

Para las tablas de diagnóstico también se reporta el bias:

$$Bias = \frac{1}{n} \sum_{i=1}^n (P_{NOCT,i} - P_{ref,i}).$$

Por esta convención, $Bias > 0$ indica sobreestimación promedio de NOCT, mientras que $Bias < 0$ indica subestimación promedio. Este signo es opuesto al signo medio del residuo ϵ .

5.7. Modelo híbrido residual con XGBoost

El enfoque híbrido utilizado en este trabajo conserva al modelo NOCT como componente físico base y entrena un modelo de aprendizaje supervisado para estimar su residuo. La variable objetivo del modelo de datos es:

$$\epsilon = P_{ref} - P_{NOCT}.$$

Si el modelo supervisado entrega una predicción $\hat{\epsilon}$, la potencia corregida se calcula como:

$$P_{hybrid} = P_{NOCT} + \hat{\epsilon}.$$

Esta formulación permite que el aprendizaje automático se concentre en las discrepancias no capturadas por el modelo físico simplificado, en lugar de aprender directamente la potencia completa desde cero. En este trabajo se utiliza XGBoost, un método de *gradient boosting* basado en árboles de decisión regularizados [4]. La comparación principal se realiza entre dos modelos residuales: uno entrenado sin fracción difusa y otro entrenado incorporando esta variable de forma explícita. De esta forma, la diferencia de desempeño entre ambos modelos entrega una medida empírica del aporte incremental de la fracción difusa.

La decisión de aprender el residuo, y no la potencia directamente, es central para el carácter híbrido del trabajo. El modelo NOCT ya contiene una relación física dominante entre irradiancia, temperatura de celda y potencia. XGBoost se usa entonces como un corrector de segundo nivel: recibe variables físicas y temporales, estima cuánto se equivoca NOCT bajo esas condiciones y ajusta la salida final. Si $\hat{\epsilon} > 0$, la corrección aumenta la potencia NOCT. Si $\hat{\epsilon} < 0$, la disminuye. Este esquema evita interpretar al modelo de datos como reemplazo de la física y permite analizar la estructura del error.

En este sentido, el aprendizaje utilizado es supervisado: durante el entrenamiento, el algoritmo observa pares formados por variables de entrada y un valor objetivo conocido, que en este caso es ϵ . A partir de esos pares ajusta sus árboles internos para aproximar el residuo. Luego, en el conjunto de prueba, se le entregan variables de entrada de horas no usadas durante el entrenamiento y se evalúa si la corrección mejora la estimación de potencia.

6. Metodología

6.1. Ubicación de estudio

La ubicación de estudio corresponde a Santiago, Chile. Esta elección se fundamenta en su alta representatividad dentro del mercado nacional de generación distribuida, la amplia disponibilidad de registros climáticos estandarizados en bases internacionales y por estar particularmente expuesta a variaciones de nubosidad por causas topográficas y costeras. Para evitar inconsistencias entre la fuente meteorológica, la geometría solar y las salidas de PVWatts, se utilizaron las coordenadas efectivas reportadas por PVWatts para su fuente internacional:

Tabla 2: Coordenadas efectivas de la ubicación de estudio.

Parámetro	Valor
Latitud	−33,3800
Longitud	−70,7800
Elevación	476 m
Fuente climática	PVWatts International
Archivo climático	855740.tm3
Distancia entre solicitud y fuente	0 km

Dado que Santiago se encuentra en el hemisferio sur, el arreglo fotovoltaico se orientó hacia el norte, utilizando azimuth 0° .

6.2. Parámetros del sistema fotovoltaico

Los parámetros utilizados en PVWatts y en el modelo NOCT se resumen en la Tabla 3.

Tabla 3: Parámetros del sistema fotovoltaico utilizado.

Parámetro	Valor
Potencia nominal DC	1 kW
Inclinación	20°
Azimut	0°
Tipo de arreglo	Fijo montado en techo
Tipo de módulo	Estándar
NOCT	45 °C
Irradiancia de referencia G_{ref}	1000 W/m ²
Temperatura de referencia T_{ref}	25 °C
Coeficiente térmico γ	−0,004 1/°C
Pérdidas globales	14 %

6.3. Metodología general

El desarrollo de este trabajo se enmarca metodológicamente en los principios de CRISP-DM (*Cross-Industry Standard Process for Data Mining*), adaptados a un contexto físico-informado. La metodología se estructura como un flujo computacional secuencial iterativo que contempla la comprensión del problema físico, la obtención y preparación de los datos, el modelado base (NOCT), el diagnóstico del error y el modelado híbrido (XGBoost), seguido de su evaluación. Primero se obtiene y prepara una base horaria simulada desde PVWatts. Luego, a partir de esta base, se calcula un modelo NOCT propio y se define el residuo respecto de la referencia simulada. En una tercera etapa se diagnostica el error del modelo físico según la fracción difusa. Finalmente, se entrenan modelos residuales con XGBoost para evaluar si una corrección híbrida mejora al modelo físico y si la fracción difusa aporta información adicional.

El flujo fue implementado mediante scripts reproducibles en Python. Sin embargo, el informe no depende de revisar dichos scripts: las decisiones metodológicas, variables utilizadas, filtros aplicados y criterios de evaluación se describen en las secciones siguientes.

6.4. Preparación de datos PVWatts

La primera etapa obtiene una simulación horaria desde PVWatts para las coordenadas efectivas de Santiago. La consulta se realiza con PVWatts V8, potencia nominal de 1 kW, inclinación de 20°, azimut 0°, arreglo fijo en techo, módulo estándar y pérdidas globales de 14 %. PVWatts entrega directamente las siguientes variables:

- *DNI*: irradiancia directa normal.
- *DHI*: irradiancia difusa horizontal.
- *POA*: irradiancia sobre el plano del arreglo fotovoltaico.
- *dc*: potencia DC simulada.
- *ac*: potencia AC simulada.
- Temperatura ambiente.
- Temperatura de celda calculada por PVWatts.
- Velocidad de viento.
- Albedo.

A partir de *DNI*, *DHI* y la posición solar local de Santiago, el procedimiento reconstruye *GHI* mediante:

$$GHI = DNI \cos(\theta_z) + DHI.$$

Posteriormente calcula:

$$fd = \frac{DHI}{GHI}.$$

Para que este cociente tenga interpretación física, la fracción difusa se calcula solo cuando *GHI* supera un umbral mínimo de 10 W/m². En horas nocturnas, de amanecer, atardecer o irradiancia muy baja, dividir por valores cercanos a cero puede generar valores numéricamente inestables y poco informativos. Por esa razón, esas horas no se incorporan al diagnóstico por régimen de fracción difusa.

Finalmente, cada hora con fracción difusa definida se clasifica en uno de los tres regímenes definidos: baja fracción difusa, régimen mixto o alta fracción difusa. La base preparada conserva las variables solares, meteorológicas, temporales y de potencia necesarias para las etapas posteriores.

6.5. Modelo NOCT y residuo

A partir de la base preparada se calcula el modelo físico NOCT. La potencia DC de PVWatts se define como referencia simulada:

$$P_{ref} = dc.$$

El modelo NOCT se calcula usando POA , temperatura ambiente, parámetros estándar del módulo y pérdidas globales equivalentes a las utilizadas en PVWatts. La implementación sigue un orden fijo para mantener trazabilidad: primero se validan las columnas requeridas de la base, luego se convierten a formato numérico las variables solares, meteorológicas y de potencia, después se calcula la temperatura de celda NOCT, posteriormente se estima la potencia DC sin pérdidas y finalmente se aplica la pérdida global del sistema. Solo después de esta secuencia se calcula el residuo:

$$\epsilon = P_{ref} - P_{NOCT}.$$

La Figura 1 resume las operaciones principales de esta etapa. Esta descripción es importante porque el modelo NOCT no se toma directamente desde PVWatts: se implementa de forma independiente para poder compararlo contra la potencia DC simulada por PVWatts.




Figura 1: Diagrama de flujo metodológico para la implementación del modelo físico NOCT y el cálculo del residuo.

Además, se generan las siguientes magnitudes derivadas:

- Potencia DC de referencia simulada por PVWatts.
- Potencia estimada por el modelo NOCT.
- Residuo del modelo físico.
- Error absoluto.
- Error relativo, calculado solo para $P_{ref} > 50\text{ W}$.
- Indicador de observaciones válidas para diagnóstico y modelado.

6.6. Criterios de filtrado y comparabilidad

No todas las horas del año meteorológico típico son igualmente informativas para diagnosticar un modelo fotovoltaico. Durante la noche o en instantes de irradiancia muy baja, las potencias simuladas son cercanas a cero y ciertas razones, como DHI/GHI o el error relativo, pueden volverse numéricamente inestables. Por esta razón se aplican filtros explícitos antes de calcular las métricas principales.

Tabla 4: Criterios de filtrado utilizados en el diagnóstico y modelado.

Criterio	Uso dentro del estudio	Motivo metodológico
$GHI > 10 \text{ W/m}^2$	Define horas con fracción difusa interpretable.	Evita dividir por irradiancias horizontales cercanas a cero al calcular $fd = DHI/GHI$.
$POA > 10 \text{ W/m}^2$	Selecciona horas comparables para potencia fotovoltaica.	Excluye condiciones donde el arreglo recibe irradiancia despreciable.
$P_{ref} > 0$	Forma parte del conjunto válido para MAE, RMSE, bias y R^2 .	Evita comparar horas sin generación DC simulada.
$P_{ref} > 50 \text{ W}$	Se usa solo para calcular error relativo.	Evita porcentajes artificialmente grandes cuando la potencia de referencia es muy baja.

Estos filtros no modifican la definición física del modelo NOCT ni de la referencia PVWatts, ya que solo determinan qué observaciones se consideran apropiadas para cada tipo de métrica. Por ello, las tablas distinguen entre observaciones válidas para métricas absolutas y observaciones con error relativo definido.

6.7. Métricas de evaluación

El desempeño de los modelos se evalúa con métricas complementarias, ya que ninguna de ellas resume por sí sola todo el comportamiento del error. En todos los casos se compara una potencia de referencia P_{ref} con una potencia estimada P_{modelo} . Para el modelo físico, $P_{modelo} = P_{NOCT}$. Para los modelos híbridos, $P_{modelo} = P_{hybrid}$.

Tabla 5: Interpretación de las métricas utilizadas.

Métrica	Qué mide	Cómo se interpreta en este trabajo
MAE	Error absoluto medio en watts.	Indica cuántos watts se desvía el modelo respecto a la referencia.
RMSE	Raíz del error cuadrático medio.	Penaliza más los errores grandes, si es mucho mayor que el MAE, sugiere errores puntuales relevantes.
Bias	Promedio de $P_{modelo} - P_{ref}$.	Valores positivos indican sobreestimación promedio, valores negativos indican subestimación promedio.
MAE relativo	MAE dividido por la media de P_{ref} .	Entrega una noción porcentual del error promedio a nivel global.
Error relativo	Error absoluto dividido por P_{ref} .	Permite comparar el error de forma proporcional; se reporta solo cuando $P_{ref} > 50$ W.

Adicionalmente, se calculan correlaciones de Pearson y Spearman entre la fracción difusa y distintas medidas de error. Pearson cuantifica asociación lineal, mientras que Spearman evalúa asociación monótona mediante rangos. La diferencia es relevante: una correlación de Pearson alta sugiere una tendencia aproximadamente lineal, mientras que Spearman puede detectar una relación ordenada aunque no sea estrictamente lineal.

6.8. Diagnóstico del residuo por fracción difusa

La tercera etapa analiza el comportamiento del error del modelo NOCT. Para evitar una inconsistencia en los filtros, las métricas absolutas se calculan sobre todas las observaciones físicamente válidas, mientras que el error relativo promedio se calcula solo sobre las observaciones donde el error relativo está definido. En este análisis, esto corresponde a 4215 observaciones para MAE, RMSE, Bias y R^2 , y 3688 observaciones para el error relativo.

Una observación se considera físicamente válida cuando corresponde a condiciones con irradiancia y potencia suficientes para comparar P_{ref} y P_{NOCT} sin que dominen efectos numéricos de borde. Esta distinción es importante porque el MAE, el RMSE y el bias se expresan en watts, mientras que el error relativo se expresa como proporción de la potencia generada. Por ello, horas con P_{ref}

muy pequeña pueden producir porcentajes grandes aunque la diferencia absoluta sea reducida.

Las métricas calculadas son:

- MAE.
- RMSE.
- Bias, definido como $P_{NOCT} - P_{ref}$.
- R^2 .
- Error relativo promedio.

También se calculan correlaciones entre fd y distintas medidas de error:

- ϵ .
- $|\epsilon|$.
- Error relativo.

Adicionalmente, se generan gráficos de diagnóstico para visualizar la relación entre el error del modelo y la fracción difusa.

6.9. Modelo híbrido residual con XGBoost

La última etapa entrena modelos supervisados para predecir el residuo:

$$\epsilon = P_{ref} - P_{NOCT}.$$

La predicción final se obtiene sumando la corrección residual estimada al modelo físico:

$$P_{hybrid} = P_{NOCT} + \hat{\epsilon}.$$

Se comparan tres configuraciones en el conjunto de prueba:

1. **Modelo físico NOCT:** modelo base sin corrección supervisada.

2. **Modelo híbrido sin fracción difusa:** modelo residual entrenado con *POA*, temperatura ambiente, velocidad de viento y variables temporales cíclicas de hora y mes.
3. **Modelo híbrido con fracción difusa:** modelo residual entrenado con las mismas variables anteriores, agregando la fracción difusa.

Para minimizar la fuga de información, el modelo sin *fd* no utiliza *DNI*, *DHI* ni *GHI*, ya que a partir de estas variables podría reconstruirse implícitamente la fracción difusa. En este contexto, fuga de información significa que una variable de entrada entrega indirectamente la misma información que se pretende evaluar como aporte nuevo. Es importante notar que la variable *POA* se utiliza en ambos modelos y ya contiene indirectamente parte de la información sobre la radiación difusa debido a la transposición, pero se mantiene para no degradar artificialmente el modelo base.

La evaluación principal utiliza una separación temporal: el primer 75 % de las observaciones válidas se usa para entrenamiento y el último 25 % para prueba. Adicionalmente, se realiza una validación temporal con `TimeSeriesSplit` de cinco particiones para verificar la estabilidad de la mejora.

La Tabla 6 resume las variables utilizadas en cada configuración. El conjunto base incluye irradiancia en el plano del panel, temperatura ambiente, velocidad de viento y variables temporales cíclicas. El modelo con fracción difusa agrega *fd* como única variable adicional. Esta construcción permite que la comparación responda directamente a la pregunta metodológica del trabajo.

Tabla 6: Variables de entrada de los modelos residuales.

Variable	Uso sin fracción difusa	Uso con fracción difusa
POA	Sí. Representa irradiancia incidente sobre el arreglo.	Sí. Se mantiene como variable física principal.
Temperatura ambiente	Sí. Afecta la temperatura de celda y eficiencia.	Sí. Misma interpretación.
Velocidad de viento	Sí. Aproxima condiciones de enfriamiento del módulo.	Sí. Misma interpretación.
Hora seno/coseno	Sí. Representa ciclo diario.	Sí. Misma transformación.
Mes seno/coseno	Sí. Representa estacionalidad anual.	Sí. Misma transformación.
Fracción difusa fd	No. Se excluye para construir el modelo de comparación.	Sí. Variable física de interés.
DNI, DHI, GHI	No. Se excluyen para evitar reconstruir fd .	No. Se excluyen para mantener la comparación controlada.

Las variables de hora y mes se transforman mediante componentes seno y coseno para representar su naturaleza cíclica:

$$h_{\sin} = \sin\left(\frac{2\pi h}{24}\right), \quad h_{\cos} = \cos\left(\frac{2\pi h}{24}\right),$$

$$m_{\sin} = \sin\left(\frac{2\pi(m-1)}{12}\right), \quad m_{\cos} = \cos\left(\frac{2\pi(m-1)}{12}\right).$$

Así, por ejemplo, las horas 23 y 0 quedan cercanas en el espacio de variables, en lugar de aparecer como valores extremos separados. Lo mismo ocurre con diciembre y enero en el ciclo anual.

La implementación del modelo híbrido se resume en la Figura 2. El punto central es que XGBoost no predice P_{ref} directamente: predice el residuo del modelo NOCT. Luego, esta corrección se suma al modelo NOCT para obtener la potencia final.




Figura 2: Diagrama de flujo metodológico de la arquitectura del modelo híbrido residual con XGBoost.

La separación temporal utilizada en el entrenamiento se resume en la Tabla 7. Se evita una división aleatoria porque observaciones horarias cercanas pueden ser muy similares entre sí. Si horas vecinas aparecen simultáneamente en entrenamiento y prueba, el desempeño podría sobreestimarse.

Tabla 7: Separación temporal utilizada en el entrenamiento del modelo híbrido.

Conjunto	Observaciones	Inicio	Fin
Entrenamiento	3161	2021-01-01 06:00	2021-10-13 09:00
Prueba	1054	2021-10-13 10:00	2021-12-31 19:00

El año 2021 que aparece en la tabla se usa solo como índice nominal para construir una secuencia horaria ordenada. No corresponde a un año histórico medido, ya que la base proviene de un año meteorológico típico.

La validación con `TimeSeriesSplit` usa particiones temporales crecientes: cada partición entrena con un bloque inicial de datos y evalúa en un bloque posterior. Este criterio respeta el orden temporal de la serie y permite comprobar si la mejora del modelo híbrido se mantiene en más de un tramo del año meteorológico típico.

Los hiperparámetros se mantuvieron fijos para los modelos con y sin fd , de modo que la comparación se atribuya al conjunto de variables y no a una configuración distinta del algoritmo. La Tabla 8 muestra los valores utilizados.

Tabla 8: Hiperparámetros principales de XGBoost.

Hiperparámetro	Valor
Objetivo	<code>reg:squarederror</code>
Número de árboles	350
Profundidad máxima	3
Tasa de aprendizaje	0,035
<code>subsample</code>	0,85
<code>colsample_bytree</code>	0,85
<code>min_child_weight</code>	3
Regularización λ	2,0
Semilla aleatoria	42

Los hiperparámetros controlan la complejidad del modelo y su tendencia a sobreajustar. En esta etapa no se realizó una búsqueda exhaustiva de hiperparámetros, porque el objetivo principal no era obtener el mejor XGBoost posible, sino comparar de manera controlada dos modelos

equivalentes salvo por la presencia de fd . Por esa razón se usó una configuración moderada y regularizada.

Tabla 9: Rol de los hiperparámetros principales de XGBoost.

Hiperparámetro	Interpretación
<code>reg:squarederror</code>	Define que el modelo resuelve una regresión minimizando error cuadrático. Es apropiado porque la variable objetivo, ϵ , es continua.
Número de árboles	Cantidad de árboles construidos secuencialmente. Más árboles aumentan capacidad de ajuste, pero también costo y riesgo de sobreajuste.
Profundidad máxima	Limita cuántas divisiones puede tener cada árbol. Una profundidad baja favorece reglas simples y reduce sobreajuste.
Tasa de aprendizaje	Controla cuánto aporta cada árbol nuevo. Valores bajos hacen el aprendizaje más gradual y estable.
<code>subsample</code>	Fracción de observaciones usada por cada árbol. Al ser menor que 1, introduce variabilidad y ayuda a regularizar.
<code>colsample_bytree</code>	Fracción de variables considerada por cada árbol. Reduce dependencia excesiva de una sola variable.
<code>min_child_weight</code>	Exige un peso mínimo para crear nuevas divisiones. Valores mayores hacen más difícil formar ramas basadas en pocos datos.
Regularización λ	Penaliza pesos grandes en las hojas de los árboles. Ayuda a suavizar el modelo y disminuir sobreajuste.
Semilla aleatoria	Fija la reproducibilidad de los resultados cuando existen procesos aleatorios internos.

Para facilitar la reproducibilidad, la Tabla 10 resume las versiones principales utilizadas en la ejecución final del flujo computacional. Estas versiones son relevantes porque pequeñas diferencias en librerías de aprendizaje automático o cálculo solar pueden modificar redondeos, particiones o valores auxiliares.

Tabla 10: Versiones principales de software utilizadas.

Herramienta	Versión
Python	3.10.0
pandas	2.3.3
NumPy	2.2.6
pvlb	0.15.2
XGBoost	3.2.0
scikit-learn	1.7.2
PVWatts API	8.5.0

7. Resultados

7.1. Base generada por PVWatts

La base horaria generada desde PVWatts contiene una serie de un año meteorológico típico. Esta serie no corresponde a una serie histórica real de un año específico, sino a una representación horaria típica disponible mediante PVWatts.

La Tabla 11 resume la base horaria descargada desde PVWatts:

Tabla 11: Resumen de la base PVWatts generada.

Característica	Valor
Filas totales	8760
Días representados	365
Duplicados de fecha/hora	0
Columnas principales	17
Dataset utilizado	intl
Fuente climática efectiva	Santiago, Chile
Distancia entre solicitud y fuente	0 km

7.2. Análisis Exploratorio de Datos (EDA)

Antes de proceder con el modelado y diagnóstico, se caracterizó el comportamiento estadístico de las principales variables operativas sobre las observaciones válidas (ver Tabla 12). La irradiancia global horizontal (GHI) presentó una media de $423,00 \text{ W/m}^2$, con una alta desviación estándar ($318,40 \text{ W/m}^2$) característica del ciclo solar. La fracción difusa mostró una media de $0,579$, lo que evidencia un aporte sustancial de la radiación difusa a lo largo del año en el entorno urbano simulado. Las temperaturas operativas fluctuaron entre $-2,0^\circ\text{C}$ y $33,2^\circ\text{C}$ para el ambiente, con un viento moderado que promedió $2,73 \text{ m/s}$. Estas condiciones base respaldan la representatividad climática de los datos para la evaluación.

Tabla 12: Estadísticas descriptivas de las variables principales en las observaciones válidas.

Estadístico	$GHI \text{ [W/m}^2\text{]}$	$POA \text{ [W/m}^2\text{]}$	fd	T. Amb. [$^\circ\text{C}$]	Viento [m/s]	P. Ref [W]
Media	423,00	458,01	0,579	18,33	2,74	365,79
Desv. Est.	318,40	343,98	0,331	7,02	2,04	266,17
Mínimo	11,00	10,39	0,092	-2,00	0,00	5,35
Máximo	1088,67	1105,37	1,000	33,20	10,80	868,20

7.3. Base final con modelo NOCT

Luego de aplicar el modelo NOCT y calcular el residuo, se obtiene una base con las variables de irradiancia, potencia PVWatts, potencia NOCT y errores. La Tabla 13 resume esta base final:

Tabla 13: Resumen de la base final utilizada para diagnóstico y modelado.

Característica	Valor
Filas totales	8760
Columnas	27
Filas válidas para diagnóstico/modelado	4215
Filas con error relativo definido	3688

La distribución de observaciones válidas por régimen de fracción difusa se presenta en la Tabla 14. Esta distribución corresponde al cálculo de GHI con geometría solar local de Santiago.

Tabla 14: Distribución de observaciones válidas por régimen de fracción difusa.

Régimen	Observaciones válidas	Con error relativo
Baja fracción difusa	1349	1349
Mixto	1126	1124
Alta fracción difusa	1740	1215

Existen observaciones suficientes en los tres regímenes para realizar el diagnóstico del residuo y entrenar modelos supervisados. La diferencia entre observaciones válidas y observaciones con error relativo se debe al filtro $P_{ref} > 50$ W, aplicado solo para evitar errores relativos artificialmente grandes en horas de potencia muy baja.

7.4. Métricas globales del modelo NOCT

La Tabla 15 muestra el desempeño global del modelo NOCT frente a la potencia DC simulada por PVWatts.

Tabla 15: Métricas globales del modelo NOCT frente a la referencia PVWatts.

Métrica	Valor
Observaciones para MAE/RMSE/Bias/ R^2	4215
Observaciones para error relativo	3688
MAE	11,05 W
RMSE	15,05 W
Bias ($P_{NOCT} - P_{ref}$)	-1,60 W
R^2	0,9968
Error relativo promedio	3,72 %
P_{ref} promedio	365,79 W
P_{NOCT} promedio	364,18 W
fd promedio	0,5797

El ajuste global es alto, lo que indica que el modelo físico reproduce adecuadamente la tendencia principal de la potencia simulada. Sin embargo, las métricas globales no describen por sí solas si

el error se comporta de manera distinta bajo diferentes regímenes radiativos.

7.5. Error por régimen de fracción difusa

El diagnóstico muestra que el error absoluto del modelo NOCT no es uniforme entre regímenes. En términos de MAE, se observa un mayor error absoluto en el régimen de baja fracción difusa, como se resume en la Tabla 16. Esto se interpreta considerando que bajo condiciones de baja fd suele existir mayor irradiancia y, por tanto, mayor potencia disponible. En consecuencia, una diferencia proporcionalmente pequeña entre modelos puede expresarse como una diferencia mayor en watts.

Tabla 16: Métricas por régimen de fracción difusa para el modelo NOCT.

Régimen	n	MAE [W]	RMSE [W]	Bias [W]	Error rel. [%]
Baja fracción difusa	1349	20,42	23,97	-14,54	2,98
Mixto	1126	7,88	9,67	2,51	3,07
Alta fracción difusa	1740	5,83	6,54	5,76	5,15

El bias se interpreta con la convención $P_{NOCT} - P_{ref}$. Por tanto, el bias negativo en baja fracción difusa indica que el modelo NOCT tiende a subestimar la referencia simulada en ese régimen. En cambio, los bias positivos en régimen mixto y alta fracción difusa indican una sobreestimación promedio. La Figura 3 muestra visualmente la diferencia de MAE entre regímenes.




Figura 3: MAE del modelo NOCT por régimen de fracción difusa para la simulación asociada a Santiago.




Figura 4: Distribución del error absoluto del modelo NOCT por régimen de fracción difusa; los valores extremos no se muestran en el boxplot.

7.6. Error relativo por régimen

Aunque el error absoluto es menor en alta fracción difusa, el error relativo muestra un comportamiento distinto. En condiciones de alta fd , la potencia disponible suele ser menor, por lo que errores absolutos pequeños pueden representar una fracción mayor de la potencia generada.

Los resultados indican que el error relativo promedio aumenta en alta fracción difusa, alcanzando aproximadamente 5,15 %. Este resultado es relevante porque sugiere que el desempeño proporcional del modelo físico puede degradarse bajo condiciones donde domina la radiación difusa.




Figura 5: Distribución del error relativo del modelo NOCT por régimen de fracción difusa (los valores extremos no se muestran en el boxplot).

Las Figuras 4 y 5 muestran de este modo que el diagnóstico absoluto y el relativo describen aspectos fuertemente complementarios del error.

7.7. Residuo del modelo NOCT frente a la fracción difusa

La Figura 6 presenta el residuo ϵ frente a fd , lo que permite observar si el error del modelo físico presenta estructura respecto al régimen radiativo. Se observa que el residuo no se distribuye de forma completamente aleatoria, sino que presenta variaciones asociadas a la fracción difusa.




Figura 6: Residuo del modelo NOCT en función de la fracción difusa.

Dado que:

$$\epsilon = P_{ref} - P_{NOCT},$$

un residuo negativo indica que el modelo NOCT sobreestima la potencia de referencia, mientras que un residuo positivo indica subestimación. La observación de estructura en este gráfico justifica la etapa posterior de modelado residual supervisado.

7.8. Correlación entre fracción difusa y error

La Tabla 17 resume las correlaciones de Pearson y Spearman entre fd y tres medidas de error. Las correlaciones con ϵ y $|\epsilon|$ se calculan sobre las 4215 observaciones válidas. La correlación con error relativo se calcula sobre las 3688 observaciones donde dicho error está definido.

Tabla 17: Correlaciones entre fracción difusa y medidas de error.

Variable de error	Pearson con fd	Spearman con fd
ϵ	-0,5610	-0,5015
$ \epsilon $	-0,5776	-0,5729
Error relativo	0,3591	0,3119

Todas las correlaciones presentadas resultaron ser estadísticamente significativas ($p < 0,01$). Es pertinente notar, sin embargo, que las observaciones corresponden a series temporales horarias, donde existe una fuerte autocorrelación intrínseca que puede tender a inflar los niveles de significancia tradicionales. Adicionalmente, se detectó una altísima colinealidad negativa explícita entre la irradiancia en el plano de arreglo (POA) y la fracción difusa ($r = -0,8867$). Esto significa que en condiciones de nubosidad, la pérdida de irradiancia total va acoplada fuertemente al aumento en la proporción de irradiancia dispersa. La correlación negativa entre fd y ϵ es consistente con el cambio de signo observado en el residuo: bajo baja fracción difusa el modelo tiende a subestimar la referencia simulada, mientras que bajo alta fracción difusa tiende a sobreestimarla. A su vez, la correlación positiva entre fd y error relativo indica que el error proporcional tiende a aumentar cuando la fracción difusa es mayor.

7.9. Comparación entre P_{NOCT} y P_{ref}

La comparación entre la potencia estimada por NOCT y la potencia de referencia simulada por PVWatts, mostrada en la Figura 7, presenta una alta concordancia global. Esto indica que el modelo físico base entrega una estimación razonable de la potencia, aunque mantiene errores residuales que pueden ser analizados y eventualmente corregidos.




Figura 7: Comparación entre potencia estimada por NOCT y potencia de referencia PVWatts.

7.10. Modelo híbrido residual con XGBoost

El modelo híbrido utiliza las observaciones válidas para entrenar modelos residuales de XGBoost. La evaluación principal se realiza con una separación temporal: el primer 75 % de los datos se utiliza para entrenamiento y el último 25 % para prueba. El conjunto de prueba contiene 1054 observaciones válidas, de las cuales 947 tienen error relativo definido bajo el criterio $P_{ref} > 50 \text{ W}$. La separación temporal no produce conjuntos climáticamente idénticos, lo que es esperable al dividir un año meteorológico típico de forma cronológica. El conjunto de entrenamiento presenta fd promedio de 0,6070, con 28,69 % de observaciones en baja fracción difusa, 26,38 % en régimen mixto y 44,92 % en alta fracción difusa. En el conjunto de prueba, fd promedio disminuye a 0,4977 y la proporción de baja fracción difusa aumenta a 41,94 %. Esta diferencia refuerza la necesidad de complementar el holdout final con validación temporal en múltiples particiones.

Esta etapa debe entenderse como una evaluación de corrección residual, no como un sistema operacional de pronóstico meteorológico. El modelo aprende a corregir la salida NOCT usando variables disponibles en la misma base horaria simulada y se evalúa en un bloque temporal no usado durante el entrenamiento. Por tanto, el objetivo es probar si el residuo contiene estructura aprendible y si fd aporta información adicional, no predecir la radiación futura a partir de pronósticos externos.

La Tabla 18 compara el modelo físico NOCT con dos versiones del modelo híbrido: una sin fracción difusa y otra incorporando explícitamente la fracción difusa. En ambos casos, XGBoost aprende el residuo ϵ y la potencia final se calcula como $P_{hybrid} = P_{NOCT} + \hat{\epsilon}$.

Esta forma de evaluación permite separar dos preguntas. La primera es si el residuo del modelo físico contiene patrones aprendibles usando variables meteorológicas y temporales. Esta pregunta se responde comparando NOCT contra el modelo híbrido sin fd . La segunda es si la fracción difusa agrega información adicional. Esta pregunta se responde comparando el híbrido sin fd contra el híbrido con fd . Por ello, la evidencia no depende solo de que XGBoost mejore a NOCT, sino de que la versión con fd mejore a una versión equivalente sin esa variable.

Tabla 18: Desempeño de los modelos en el conjunto temporal de prueba.

Modelo	MAE [W]	RMSE [W]	Bias [W]	Error rel. [%]	Mejora MAE [%]
Modelo físico NOCT	13,30	17,10	-4,05	3,96	0,00
Híbrido sin fracción difusa	2,70	3,73	0,92	0,94	79,67
Híbrido con fracción difusa	2,22	3,01	1,13	0,83	83,27

El modelo híbrido sin fracción difusa reduce el MAE desde 13,30 W hasta 2,70 W, lo que muestra que el residuo del modelo NOCT contiene estructura aprendible a partir de variables físicas y temporales. Al incorporar la fracción difusa, el MAE disminuye adicionalmente hasta 2,22 W. Esto corresponde a una mejora de 83,27 % respecto al modelo físico NOCT y a una mejora adicional de aproximadamente 17,69 % respecto al híbrido sin fracción difusa.

El hecho de que el modelo sin fd ya reduzca fuertemente el error indica que parte de la discrepancia entre NOCT y PVWatts está asociada a variables generales del estado operativo del sistema, como irradiancia en el plano del panel, temperatura, viento y ciclos horarios o estacionales. La mejora adicional al incluir fd indica que, aun después de considerar esas variables, la composición directa-difusa de la irradiancia conserva información predictiva sobre el residuo.

La Tabla 19 compara el desempeño en entrenamiento y prueba. Como es esperable, los modelos

supervisados presentan menor error en entrenamiento que en prueba. No obstante, la mejora respecto al NOCT se mantiene en el conjunto temporal no usado para entrenar, lo que indica que el resultado no corresponde solo a ajuste sobre los datos de entrenamiento.

Tabla 19: Comparación de MAE y RMSE en entrenamiento y prueba.

Conjunto	Modelo	MAE [W]	RMSE [W]	Mejora MAE [%]
Entrenamiento	Modelo físico NOCT	10,30	14,30	0,00
Entrenamiento	Híbrido sin fracción difusa	1,46	2,02	85,82
Entrenamiento	Híbrido con fracción difusa	1,11	1,49	89,24
Prueba	Modelo físico NOCT	13,30	17,10	0,00
Prueba	Híbrido sin fracción difusa	2,70	3,73	79,67
Prueba	Híbrido con fracción difusa	2,22	3,01	83,27

La diferencia entre entrenamiento y prueba se interpreta como una verificación de generalización. Si el modelo híbrido solo estuviera memorizando los datos de entrenamiento, se esperaría una mejora grande en entrenamiento y una pérdida marcada de desempeño en prueba. En cambio, aunque el error aumenta al pasar al bloque temporal de prueba, el MAE se mantiene muy por debajo del NOCT base. Esto sugiere que el modelo residual aprende patrones persistentes del error físico y no solamente fluctuaciones particulares del conjunto de entrenamiento. La Figura 8 resume la reducción de MAE en el conjunto de prueba.




Figura 8: Comparación del MAE entre el modelo físico NOCT y los modelos híbridos en el conjunto de prueba.

7.11. Desempeño del modelo híbrido por régimen

La Tabla 20 muestra el MAE de cada modelo separado por régimen de fracción difusa. La mejora del modelo híbrido con fracción difusa se observa en los tres regímenes, aunque su magnitud absoluta depende del nivel de error inicial del modelo NOCT.

Tabla 20: MAE por régimen de fracción difusa en el conjunto temporal de prueba.

Régimen	NOCT [W]	Híbrido sin fracción difusa [W]	Híbrido con fracción difusa [W]	Mejora con fd vs. NOCT [%]
Baja fracción difusa	21,13	2,34	2,03	90,40
Mixto	9,27	3,33	2,95	68,14
Alta fracción difusa	6,16	2,64	1,83	70,23

En baja fracción difusa, donde el modelo NOCT presentaba el mayor error absoluto, el híbrido con fracción difusa reduce el MAE desde 21,13 W hasta 2,03 W. En alta fracción difusa, donde el error relativo del NOCT era más alto, el MAE disminuye desde 6,16 W hasta 1,83 W. Por tanto, la corrección residual mejora tanto las condiciones de mayor potencia como aquellas donde la componente difusa domina. La Figura 9 permite comparar visualmente esta reducción por régimen.




Figura 9: MAE del modelo físico NOCT y de los modelos híbridos por régimen de fracción difusa.

7.12. Residuo corregido e importancia de variables

La Figura 10 compara el residuo del modelo NOCT con el residuo del modelo híbrido con fracción difusa en el conjunto de prueba. La dispersión residual disminuye de forma visible, lo que es

consistente con la reducción de MAE y RMSE reportada en la Tabla 18.




Figura 10: Residuo del modelo físico NOCT y del modelo híbrido con fracción difusa frente a la fracción difusa.




Figura 11: Comparación entre potencia híbrida corregida y potencia de referencia PVWatts en el conjunto de prueba.

La Figura 11 muestra que la potencia corregida por el modelo híbrido mantiene una alta concordancia con la referencia simulada en el conjunto de prueba. El recorte a cero aplicado por consistencia física no se activó en este conjunto. Empíricamente, se verificó que en todas las fases de modelado (entrenamiento, prueba y validación cruzada en 5 pliegues) las potencias híbridas corregidas crudas siempre se mantuvieron en niveles positivos, lo que equivale a una frecuencia de activación del clipping del 0,00 %. Esto evidencia que el modelo residual no requiere truncamientos artificiales invasivos bajo este esquema metodológico.

La importancia de variables del modelo con fracción difusa se muestra en la Tabla 21 y en la Figura 12. Se reportan las cinco variables de mayor importancia entre las ocho variables de entrada del modelo con fd . La importancia corresponde a la ganancia normalizada utilizada por XGBoost para cuantificar cuánto contribuyen las divisiones asociadas a cada variable dentro del ensamble. La fracción difusa aparece como la variable de mayor importancia relativa dentro del modelo entrenado. Esta observación no debe interpretarse como causalidad física directa, pero sí como evidencia de que fd aporta información predictiva para la corrección residual.

Tabla 21: Cinco variables con mayor importancia relativa en el modelo híbrido con fracción difusa.

Variable	Importancia
Fracción difusa	0,299
Velocidad de viento	0,239
Irradiancia en el plano del panel	0,157
Temperatura ambiente	0,142
Hora, componente seno	0,062




Figura 12: Importancia de variables del modelo híbrido con fracción difusa.

7.13. Validación temporal complementaria

Además del conjunto de prueba final, se realizó una validación temporal con cinco particiones crecientes mediante `TimeSeriesSplit`. Esta verificación permite evaluar si la mejora del modelo con fracción difusa se mantiene en distintos bloques temporales. La Tabla 22 reporta el promedio y la desviación estándar muestral de las métricas calculadas sobre las cinco particiones.

Tabla 22: Resumen de validación temporal con cinco particiones, reportando promedio $\pm$ desviación estándar muestral.

Modelo	MAE promedio [W]	RMSE promedio [W]	Error rel. promedio [%]
Híbrido sin fracción difusa	$3,37 \pm 1,32$	$4,44 \pm 1,60$	$1,38 \pm 0,75$
Híbrido con fracción difusa	$2,52 \pm 0,64$	$3,36 \pm 0,85$	$1,04 \pm 0,30$

El modelo con fracción difusa obtiene menor MAE promedio que el modelo sin fracción difusa en la validación temporal. Además, obtiene menor MAE en las cinco particiones temporales evaluadas y la desviación estándar del MAE disminuye, lo que sugiere un desempeño más estable entre particiones temporales. En conjunto, estos resultados respaldan la incorporación de la fracción difusa dentro del modelo híbrido residual.

8. Discusión

Los resultados muestran que el modelo NOCT, una vez ajustado para considerar pérdidas globales equivalentes a las usadas en PVWatts, presenta un buen ajuste general respecto a la potencia simulada de referencia. Esto es esperable, dado que ambos enfoques comparten una dependencia fuerte con la irradiancia sobre el plano del arreglo fotovoltaico. No obstante, el alto R^2 global no implica ausencia de error estructurado.

El análisis por régimen de fracción difusa muestra que el error del modelo NOCT no es uniforme. En baja fracción difusa se observa mayor error absoluto, asociado a condiciones de mayor irradiancia y potencia disponible. En cambio, en alta fracción difusa el error absoluto disminuye, pero el error relativo aumenta. Además, el signo del bias cambia entre regímenes: bajo baja fracción difusa P_{NOCT} tiende a subestimar la referencia simulada, mientras que bajo alta fracción difusa tiende a sobreestimarla. Esta transición indica que el residuo contiene estructura asociada al régimen radiativo.

La correlación entre fd y las medidas de error respalda esta interpretación. La correlación negativa entre fd y ϵ muestra que el residuo cambia sistemáticamente con la fracción difusa, mientras que la correlación positiva entre fd y el error relativo indica que el error proporcional tiende a aumentar cuando la componente difusa domina. Por tanto, fd es una variable diagnóstica relevante para entender cuándo el modelo físico simplificado pierde precisión relativa.

El modelo híbrido residual confirma que el residuo del modelo NOCT no es puramente aleatorio.

En el conjunto temporal de prueba, el modelo híbrido sin fracción difusa reduce el MAE desde 13,30 W hasta 2,70 W. Esto indica que variables como *POA*, temperatura, viento, hora y estacionalidad contienen información suficiente para corregir parte importante de la discrepancia entre NOCT y PVWatts. Al incorporar la fracción difusa, el MAE disminuye adicionalmente hasta 2,22 W, y la validación temporal también muestra menor MAE promedio para el modelo que incluye esta variable. Por lo tanto, la fracción difusa aporta información incremental respecto al conjunto de variables base considerado.

La importancia de la velocidad de viento también entrega una lectura física de gran relevancia, posicionándose como la segunda variable más importante del ensamble (0,239). Esto es coherente con una limitación evidente del modelo NOCT utilizado: su formulación estima la temperatura de celda a partir de *POA* y temperatura ambiente, pero ignora explícitamente el enfriamiento convectivo por viento. Puesto que el viento captura gran parte de la señal residual, es necesario debatir si el aporte del modelo *con fd* podría, en menor medida, estar compensando algún efecto secundario del balance térmico en el modelo PVWatts subyacente. En cualquier caso, parte sustancial del residuo modelado por XGBoost claramente responde a diferencias de balance térmico no capturadas inicialmente.

La mejora debe leerse junto con el diseño de comparación. El modelo sin fracción difusa no recibe *DNI*, *DHI* ni *GHI*, porque esas variables permitirían reconstruir *fd* de manera indirecta. De esta forma, la comparación no favorece artificialmente al modelo base ni al modelo con *fd*: ambos comparten las mismas variables meteorológicas y temporales, y solo difieren en la presencia explícita de la fracción difusa. Esta decisión hace que la mejora observada sea una evidencia más directa del aporte incremental de *fd*.

La elección de XGBoost también debe interpretarse desde el tipo de datos disponible. La base final contiene variables tabulares horarias y un número de observaciones válidas moderado. En este escenario, un modelo de aprendizaje profundo podría introducir mayor complejidad, más hiperparámetros y menor interpretabilidad sin garantizar una mejora proporcional. XGBoost ofrece una alternativa más adecuada para esta etapa: modela no linealidades, permite regularización, trabaja bien con datos tabulares y entrega una medida diagnóstica de importancia de variables. Por ello, el corazón del enfoque no es la profundidad de una red neuronal, sino el acoplamiento entre un modelo físico interpretable y un corrector residual supervisado.

Es crucial precisar el límite de atribución causal de esta conclusión. La correlación observada entre la fracción difusa y el residuo del modelo NOCT sugiere una asociación, pero no implica

directamente causalidad física. El residuo podría reflejar, parcial o totalmente, otras diferencias estructurales internas entre la simple ecuación de temperatura de celda y el motor de cálculo más robusto integrado en PVWatts. Los resultados no demuestran que fd sea la única causa física intrínseca del error ni que explique por sí sola todas las discrepancias de este modelo simplificado. La potencia de referencia proviene de PVWatts, no de mediciones reales, por lo que el modelo híbrido aprende a corregir NOCT respecto a una referencia simulada. Aun sí, dentro de este marco metodológico, la comparación controlada entre modelos con y sin fd entrega evidencia consistente de que la fracción difusa mejora la corrección residual.

9. Alcances y limitaciones

1. La potencia de referencia utilizada corresponde a una simulación de PVWatts, no a una medición experimental real de un panel fotovoltaico.
2. La serie horaria descargada corresponde a un año meteorológico típico, no a una serie histórica real medida en Santiago.
3. Para Santiago se utilizó el dataset internacional de PVWatts, ya que la API no encontró datos disponibles bajo `dataset=nsrdb`.
4. La fuente climática efectiva reportada por PVWatts corresponde a Santiago, Chile, con distancia cero respecto de las coordenadas usadas en la consulta. Por tanto, se elimina la inconsistencia espacial entre ubicación solicitada y fuente climática efectiva.
5. La reconstrucción de GHI se realizó usando la geometría solar de las coordenadas efectivas de Santiago. Sin embargo, DNI , DHI , POA , temperatura y potencia PVWatts provienen de la simulación entregada por la plataforma.
6. El POA utilizado proviene directamente de la salida horaria de PVWatts. No fue calculado de forma independiente a partir de GHI , DHI , DNI y geometría solar.
7. El modelo NOCT implementado utiliza parámetros estándar y no fue calibrado con mediciones reales.
8. El modelo híbrido fue entrenado y evaluado respecto a la misma fuente simulada de referencia. Por tanto, su desempeño no debe interpretarse como validación experimental en terreno.

9. El modelo híbrido debe interpretarse como un corrector residual de NOCT respecto a PVWatts. No reemplaza una validación con mediciones reales ni constituye por sí solo un sistema de pronóstico operacional.
10. No se entrenaron modelos de aprendizaje profundo. La tesis utiliza aprendizaje automático supervisado con XGBoost, elegido por su buen comportamiento en datos tabulares, menor complejidad relativa e interpretabilidad diagnóstica.
11. El cálculo de fd excluye horas con $GHI \leq 10 \text{ W/m}^2$, y el error relativo se calcula solo cuando $P_{ref} > 50 \text{ W}$. Estos filtros reducen distorsiones numéricas, pero condicionan la interpretación de las métricas porcentuales.
12. El estudio considera una ubicación, una configuración fotovoltaica fija y un año meteorológico típico. La generalización a otras zonas climáticas, inclinaciones, tecnologías de módulo o bases meteorológicas requiere evaluaciones adicionales.
13. Las importancias de variables de XGBoost deben interpretarse como indicadores predictivos internos del modelo, no como una demostración causal de los mecanismos físicos involucrados.

10. Conclusiones

El desarrollo de este proyecto permitió dar respuesta a la pregunta de investigación mediante una secuencia alineada con los cinco objetivos específicos propuestos. A partir de los resultados, se concluye lo siguiente:

1. **Construcción de base y clasificación (Obj. 1):** Se consolidó con éxito una base horaria simulada para Santiago, obteniendo observaciones balanceadas (1349 en baja fracción difusa, 1126 en régimen mixto y 1740 en alta fracción difusa). Esto confirma que la definición metodológica de $fd = DHI/GHI$ fue operable y discriminante sobre los datos climáticos utilizados.
2. **Implementación del modelo físico (Obj. 2):** El modelo físico NOCT reprodujo adecuadamente la tendencia principal de la generación ($R^2 = 0,9968$). Sin embargo, su precisión fluctuó, mostrando errores absolutos dominantes en alta irradiancia y sesgos relativos dependientes de la fracción difusa.

3. **Diagnóstico del residuo (Obj. 3):** El residuo del modelo NOCT demostró empíricamente no ser aleatorio. Se comprobó una asociación sistemática ($p < 0,01$) con la fracción difusa, revelando que en alta fd el modelo físico tiende a sobreestimar la producción relativa, lo que degrada la estimación porcentual bajo irradiancia dispersa.
4. **Corrección residual con aprendizaje automático (Obj. 4):** El entrenamiento de modelos híbridos sobre el residuo físico logró reducir dramáticamente el error del modelo base. La aproximación demostró que variables como temperatura, radiación incidente y velocidad de viento (esta última fundamental en el balance térmico no capturado por NOCT) albergan señales suficientes para minimizar las discrepancias (reduciendo el MAE de prueba de 13,30 W a 2,70 W).
5. **Aporte incremental de la fracción difusa (Obj. 5):** Al comparar el modelo híbrido sin fd frente al modelo con fd , el MAE de prueba se redujo adicionalmente un 17,69 % (hasta 2,22 W), sin activación artificial de recortes por truncamiento físico (0 % clipping). Esto confirma empíricamente la hipótesis: incorporar la fracción difusa provee información estructural predictiva novedosa, validando así su valor y aporte general.

Por consiguiente, el objetivo general de la investigación se declara cumplido. La fracción difusa probó ser tanto un diagnóstico revelador de las debilidades térmico–radiativas de modelos físicos simples, como un atributo clave para enriquecer modelos de regresión híbrida orientados a la estimación fotovoltaica. Naturalmente, la principal limitación a abordar a futuro es el carácter simulado de la referencia (PVWatts), abriendo vías para un futuro escalamiento y validación experimental.

11. Trabajo futuro

Como extensión natural de este trabajo, se propone validar el flujo metodológico con mediciones reales de potencia fotovoltaica, irradiancia y meteorología local. Esta validación permitiría determinar si la mejora observada frente a PVWatts se mantiene respecto a un sistema físico instrumentado.

También se recomienda ampliar el análisis a más ubicaciones, distintos regímenes climáticos, diferentes inclinaciones y tecnologías de módulo. Esto permitiría evaluar la generalidad del aporte de fd y distinguir si su relevancia depende de condiciones atmosféricas o geométricas particulares.

Otra línea de trabajo consiste en calcular el *POA* de forma independiente a partir de *GHI*, *DNI*, *DHI*, geometría solar y modelos de transposición, en lugar de utilizar directamente el *POA* entregado por PVWatts. Esto permitiría separar mejor las fuentes de error asociadas a geometría, irradiancia y temperatura.

Finalmente, se podrían explorar estrategias de optimización de hiperparámetros con validación temporal anidada, modelos con incertidumbre predictiva y métodos de interpretabilidad como SHAP. En una etapa posterior, también podrían evaluarse modelos de aprendizaje profundo si se dispone de bases más extensas, múltiples ubicaciones o secuencias meteorológicas de mayor complejidad. Estas extensiones ayudarían a robustecer la interpretación del modelo híbrido y su posible uso en aplicaciones de estimación o predicción fotovoltaica.

Referencias

- [1] Ramadhan, R. W. y Naseem, A. (2021). *Recent Trends in Photovoltaic Power Forecasting*. Energies, 14(20), 6610.
- [2] Erbs, D. G., Klein, S. A. y Duffie, J. A. (1982). *Estimation of the diffuse radiation fraction for hourly, daily and monthly-average global radiation*. Solar Energy, 28(4), 293–302.
- [3] NREL (2026). *PVWatts Calculator*. National Renewable Energy Laboratory. <https://pvwatts.nrel.gov/>
- [4] Chen, T. y Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Actas de la 22.a Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos.
- [5] Mayer, M. J. y Gróf, G. (2022). *Benefits of physical and machine learning hybridization for photovoltaic power forecasting*. Renewable and Sustainable Energy Reviews, 168, 112772.
- [6] Santos, L. O., et al. (2024). *Photovoltaic power estimation and forecast models integrating physics and machine learning: A review on hybrid techniques*. Solar Energy, 270, 112377.

A. Anexo: Glosario de Conceptos

***Residual learning* (aprendizaje residual):** Enfoque de modelado donde un algoritmo de aprendizaje automático no predice directamente el valor objetivo final, sino la discrepancia (o residuo) respecto a una aproximación previa (como un modelo físico). Esto facilita que el algoritmo se concentre solo en capturar los fenómenos complejos no modelados inicialmente.

pvlib**:** Biblioteca de código abierto en lenguaje Python especializada en la simulación de rendimiento de sistemas de energía solar fotovoltaica. Provee funciones estandarizadas para cálculos astronómicos, irradiancia, térmicos y eléctricos.

Ángulo cenital solar (θ_z): Ángulo que se forma entre la dirección del sol y el cenit (la vertical exacta del lugar). Se calcula algorítmicamente en función de la latitud, longitud, altitud y fecha, y determina qué proporción de la radiación directa normal (*DNI*) incide sobre un plano horizontal.